Detekcija intracerebralnog krvarenja na CT slikama mozga

Karla Budimir, Anja Obuljen, Marko Sršić, Nela Štubelj

U ovom projektu razvijen je sustav za automatsku detekciju intracerebralnog krvarenja na CT slikama mozga primjenom tehnika digitalne obrade slike i klasičnih metoda strojnog učenja. Sustav se temelji na predobradi CT slika, segmentaciji potencijalnih regija krvarenja, ekstrakciji vizualnih značajki (intenzitet, tekstura, oblik) te klasifikaciji slika na klase krvarenje i bez krvarenja. Ispitane su različite skupine značajki (intenzitetske, teksturalne i geometrijske) te više klasifikacijskih modela, uključujući logističku regresiju, SVM, Random Forest i XGBoost. Dobiveni rezultati pokazuju da kombinacija pažljivo odabranih značajki i ansambl modela omogućuje pouzdanu detekciju krvarenja, uz dobru interpretabilnost i relativno nisku računalnu složenost.

Keywords— CT mozga, intracerebralno krvarenje, obrada slike, ekstrakcija značajki, strojno učenje

I. Uvod

Intracerebralno krvarenje predstavlja ozbiljno medicinsko stanje koje zahtijeva brzu i točnu dijagnostiku. CT snimanje mozga je standardna metoda prve linije za detekciju krvarenja zbog brzine i dostupnosti.

Unatoč visokoj pouzdanosti CT snimanja, manualna analiza slika u kliničkoj praksi može biti vremenski zahtjevna i podložna subjektivnim procjenama, osobito u hitnim situacijama. Osim toga, suptilne promjene u ranim fazama krvarenja ili manja žarišta mogu biti teško uočljiva ljudskom oku uslijed zamora, što povećava rizik od dijagnostičkih propusta. Iz ovih razloga, integracija algoritamske podrške u klinički tijek rada te razvoj automatiziranih sustava za detekciju krvarenja može značajno doprinijeti ranom prepoznavanju i podršci kliničkom odlučivanju.

Cilj ovog projekta je istražiti u kojoj mjeri klasične metode obrade slike i strojnog učenja mogu učinkovito razlikovati CT slike s krvarenjem od onih bez krvarenja, bez potrebe za složenim dubokim neuronskim mrežama. Ovakav pristup omogućuje bolje razumijevanje utjecaja specifičnih značajki slike na točnost same klasifikacije - metode niže računalne složenosti nude veću interpretabilnost rezultata i olakšavaju implementaciju.

II. Povezani radovi

Postojeći radovi u području detekcije intracerebralnog krvarenja koriste širok raspon pristupa, od heurističkih metoda temeljenih na jednostavnoj obradi slike do naprednih metoda dubokog učenja, uključujući konvolucijske neuronske mreže (CNN) i modele temeljene na 3D CT volumenima [1], [2].

Raniji pristupi primarno su se oslanjali na činjenicu da se akutno krvarenje na CT slici pojavljuje kao hiperdenzna (svjetlija) regija, što omogućuje primjenu pragiranja i analize intenziteta. Iako računalno učinkovite, ove metode često generiraju lažne detekcije zbog sličnosti u intenzitetu između krvarenja i normalnih struktura poput kosti lubanje i kalcifikacija.

Kasnija istraživanja uvode teksturalne značajke kako bi se prevladali navedeni nedostaci. Korištenje statističkih značajki u kombinaciji s GLCM (*Gray-Level Co-occurrence Matrix*) [3] značajkama značajno poboljšava klasifikaciju, omogućujući modelu da razlikuje homogenu strukturu kosti od heterogene teksture krvarenja.

LBP (*Local Binary Patterns*) [4] deskriptori pokazali su se iznimno uspješnima u detekciji suptilnih promjena u teksturi tkiva, zbog čega se ova metoda danas često koristi u analizi medicinskih slika.

U novije vrijeme, fokus istraživanja pomaknuo se prema dubokom učenju. Iako duboki modeli često postižu veću točnost, oni zahtijevaju velike skupove podataka i značajne računalne resurse, te često funkcioniraju kao ‘crne kutije’ s niskom interpretabilnošću, što ih čini manje prikladnima za sustave s ograničenim kapacitetima. Iz tih razloga, u ovom projektu fokusiramo se na interpretabilne i računalno učinkovitije metode, čime se osigurava veća transparentnost procesa donošenja odluka, nužna za primjenu u medicinskoj praksi.

III. Opis rješenja

A. UVOD

Cilj projekta je izrada automatiziranog sustava za detekciju intracerebralnog krvarenja na slikama korištenjem tehnika digitalne obrade slike i klasičnog strojnog učenja.

B. SKUP PODATAKA I PRETPROCESIRANJE

U projektu je korišten javno dostupan skup podataka Head CT Hemorrhage (Kaggle), koji sadrži CT slike mozga podijeljene u dvije klase:

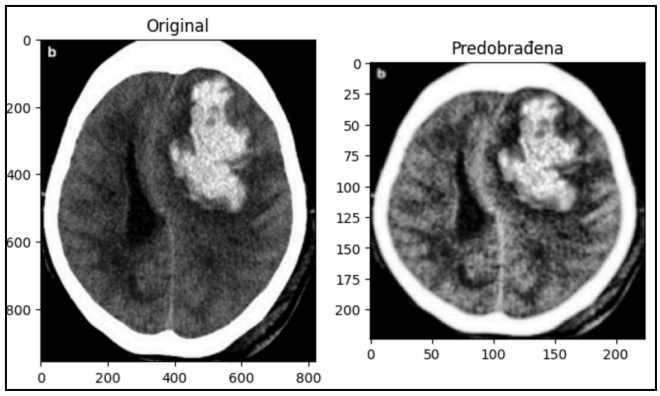
1. slike s prisutnim intracerebralnim krvarenjem
2. slike bez krvarenja

Svaka klasa sadrži 100 slika s pripadajućom binarnom oznakom (krvarenje / bez krvarenja). Skup je uravnotežen, što je važno za stabilno treniranje modela i smanjivanje pristranosti prema pojedinim klasama. Same slike koje se

nalaze u skupu su 2D presjeci mozga u sivim tonovima (*greyscale*).

Prije korištenja podataka za učenje modela potrebno je napraviti predobradu CT slika kako bi sve bile u istom formatu i dimenzijama. Na taj način se osigurava konzistentnost ulaznih vektora koji će kasnije biti izračunati iz CT slika koja je nužna za stabilno treniranje modela strojnog učenja.

U svim eksperimentima ulazne slike skalirane su na rezoluciju 224×224 piksela, čime je osigurana konzistentna prostorna dimenzija ulaza i usporedivost rezultata među modelima. Na slikama je uklonjen šum pomoću Gaussian zamućivanja s malom jezgrom (3×3) kako bi se smanjio visokofrekventni šum koji je česta pojava na CT snimkama, bez značajnog gubitka strukturnih detalja. Za poboljšanje kontrasta korištena je CLAHE metoda (Contrast Limited Adaptive Histogram Equalization) koja lokalno poboljšava kontrast slike. Time se naglašavaju suptilne strukture i lezije, dok se istovremeno sprječava pretjerano pojačavanje šuma. Slika 1. prikazuje usporedbu originalne CT slike iz skupa podataka i predobrađene slike nakon primjene svih opisanih koraka.



Slika 1. Originalna i predobrađena slika CT mozga

Možemo uočiti da predobrađena slika ima izraženiji kontrast između krvarenja i okolnog tkiva. Rubovi i strukture mozga su jasnije definirani i smanjen je utjecaj šuma što olakšava daljnju segmentaciju i klasifikaciju. Ovakva predobrada stvara kvalitetniji ulaz za izdvajanje značajki i treniranje klasifikacijskog modela.

C. SEGMENTACIJA SLIKE

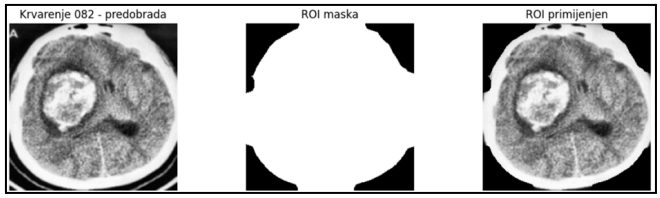
Pretprocesiranjem smo dobili konzistentan skup slika, no one još uvijek mogu sadrže određenu količinu nepotrebnih informacija - artefakata (npr. tekstualne anotacije). Kako bi se izolirale potencijalne regije krvarenja i smanjio utjecaj pozadine potrebno je napraviti segmentaciju slika, odnosno ekstrakciju regije interesa *ROI*.

Procedura izdvajanja regije interesa uključivala je primjenu praga na sliku, morfološke operacije te izdvajanje najveće povezane komponente (*LCC - Largest Connected Component*).

Za inicijalno razdvajanje područja mozga od pozadine primijenjena je metoda automatskog odabira praga temeljena na histogramu sivih tonova, poznata kao Otsuova metoda [5]. Na CT slici lubanja ima vrlo visoke intenzitete piksela. Pragiranje svijetlih vrijednosti izdvaja se prsten lubanje koji će biti pouzdani orijentir za lokalizaciju mozga. Morfološko zatvaranje koristi se za povezivanje diskontinuiranih dijelova prstena lubanje i uklanjanje malih praznina uzrokovanih šumom ili anatomskim varijacijama. Primjenom LCC postupka zadržava se najveća povezana komponenta slike. Unutrašnjost prstena lubanje se popunjava kako bi se dobila maska koja pokriva cijelu intrakranijalnu regiju, a ne samo kost. Maska se dodatno erodira kako bi se smanjio utjecaj same kosti koja je izrazito hiperdenzna, te se fokus prebacio na moždani parenhim. Dobivena maska se primjenjuje na predobrađenu CT sliku čime nastaje ROI slika koja sadrži isključivo intrakranijalnu regiju.

Rezultat segmentacije su binarne maske koje označavaju regiju mozga koja se koristi za daljnju analizu i klasifikaciju krvarenja.

Iako se krvarenje ne segmentira eksplicitno, ovim postupkom ograničili smo analizu na anatomsku regiju u kojoj se krvarenje može pojaviti i time smanjili utjecaj irelevantnih piksela u kasnijim koracima (izdvajanje značajki, klasifikacija). Slika 2. prikazuje ROI masku primijenjenu na predobrađenu sliku krvarenja.

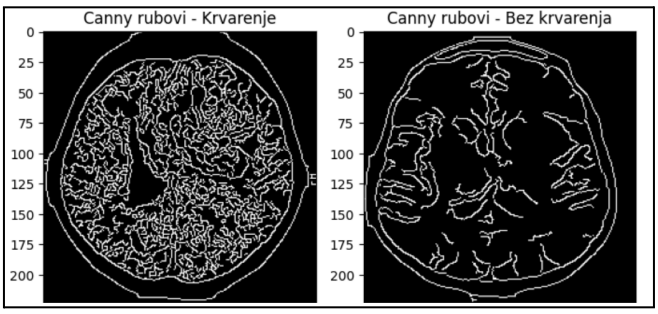


Slika 2. ROI maska primijenjena na sliku

D. EKSTRAKCIJA ZNAČAJKI

Nakon provedene predobrade i segmentacije regije interesa, sljedeći korak je ekstrakcija značajki čiji je cilj pretvoriti vizualne informacije iz CT slike u numeričke značajke pogodne za strojno učenje.

Iz segmentiranih regija izdvojene su 3 skupine značajki: intenzitetske, rubne i teksturalne. Intenzitetske značajke opisuju distribuciju sivih razina unutar ROI-a i uključuju statistike intenziteta (srednja vrijednost, standardna devijacija, asimetrija, zakrivljenost) te udio svijetlih piksela koji kvantificira hiperdenzna područja karakteristična za krvarenje. Značajke temeljene na rubovima pogodne su za analizu jer krvarenje često uzrokuje oštre prijelaze intenziteta. Zbog toga računamo prosječnu jačinu gradijenta (*Sobel*) i gustoću rubova (*Canny*) prikazanu na Slici 3. Uočeno je da slike s krvarenjem pokazuju veće vrijednosti ovih mjera. Za opis lokalne strukture tkiva korištene su GLCM značajke - kontrast, homogenost, energija i korelacija, te LBP značajke koje kvantificiraju teksturalnu heterogenost uzrokovanu krvarenjem. Sve izdvojene značajke kombiniraju se u jedinstveni vektor značajki za svaku sliku koji se naposljetku standardizira korištenjem *StandardScaler* metode.



Slika 3. Canny detekcija rubova primijenjena na sliku krvarenja

E. MODELI STROJNOG UČENJA

Za klasifikaciju CT slika na one koje sadrže intracerebralno krvarenje i na one koje ga ne sadrže implementirani su i uspoređeni sljedeći modeli:

Logistička regresija: osnovni model za binarnu klasifikaciju, često korišten kao referentna točka zbog svoje jednostavnosti i interpretabilnosti.

Stroj potpornih vektora (*SVM*) s radijalnom baznom funkcijom (*RBF kernel*): model poznat po svojoj sposobnosti pronalaženja optimalne hiperravnine u implicitno transformiranom prostoru za razdvajanje klasa, učinkovit u visoko-dimenzionalnim prostorima značajki.

Random Forest: ansambl model temeljen na stablima odlučivanja poznat po robusnosti, dobroj generalizaciji, otpornosti na šum i sposobnosti rukovanja s velikim brojem značajki te procjeni njihove važnosti.

XGBoost (*Extreme Gradient Boosting*): napredni ansambl model temeljen na gradijentnom pojačavanju, koji sekvencijalno gradi stabla odlučivanja ispravljajući pogreške prethodnih. Smatra se industrijskim standardom za postizanje visoke točnosti na strukturiranim podacima.

Višeslojni perceptron (*MLP*): jednostavna neuronska mreža s jednim ili više skrivenih slojeva, sposobna modelirati nelinearne odnose između značajki i ciljne varijable. U ovom projektu korištena su dva skrivena sloja, od kojih se jedan sastojao od 64, a drugi od 32 neurona.

Cjelokupan proces učenja proveden je u nekoliko standardiziranih koraka kako bi se osigurala valjanost rezultata i sposobnost generalizacije modela.

Sve spomenute značajke (intenzitetske, rubne, teksturalne) spojene su u jedinstvenu matricu značajki X, dok su pripadajuće dijagnoze (krvarenje / bez krvarenja) sadržane u vektoru oznaka y.

Skup podataka podataka podijeljen je na skup za učenje i skup za testiranje u omjeru 80:20 pri čemu je korištena stratifikacija kako bi se osigurao isti omjer klasa u oba podskupa kakav je bio i u originalnom skupu.

Budući da korišteni algoritmi, posebice SVM i MLP, ovise o rasponu vrijednosti ulaznih podataka, provedena je standardizacija podataka. Standardizacijom podataka svaka se značajka transformira tako da ima srednju vrijednost 0 i jediničnu varijancu.

Svaki od pet definiranih modela inicijaliziran je s ručno odabranim hiperparametrima nakon čega je pokrenut proces učenja nad trening skupom. Algoritmi su iterativno prilagođavali svoje parametre s ciljem minimiziranja pogreške klasifikacije.

F. EVALUACIJA

Evaluacija performansi razvijenih modela strojnog učenja provodi se s ciljem objektivne procjene njihove sposobnosti razlikovanja CT slika s intracerebralnim krvarenjem od onih bez krvarenja. Predviđanja modela na testnom skupu uspoređena su sa stvarnim oznakama slika, a učinkovitost modela izmjerena je korištenjem dviju standardnih metrika:

Točnost (*Accuracy*): omjer ispravno klasificiranih slika u odnosu na ukupan broj slika.

Odziv (*Recall*): omjer ispravno klasificiranih pozitivnih primjera i ukupnog broja stvarnih pozitivnih primjera. U medicinskoj dijagnostici ovo je često najvažnija metrika, jer minimiziranje lažno negativnih rezultata osigurava da patološka stanja (u našem slučaju krvarenje)ne ostanu neotkrivena.

Dodatno, analizirane su i matrice zabune kako bi se dobio detaljniji uvid u tipove pogrešaka koje modeli čine.

G. IMPLEMENTACIJSKI DETALJI

Cjelokupni sustav za detekciju krvarenja u mozgu, uključujući pretprocesiranje slika, segmentaciju, ekstrakciju značajki, treniranje modela i evaluaciju, razvijen je u programskom jeziku Python. U nastavku su navedene najvažnije korištene biblioteke.

OpenCV (cv2): za sve osnovne operacije obrade slike, uključujući učitavanje CT slika u sivim tonovima, promjenu rezolucije (*resize*), uklanjanje šuma Gaussovim filtrom, poboljšanje kontrasta pomoću CLAHE metode, pragiranje intenziteta, morfološke operacije (opening, closing, erosion), detekciju rubova (Canny), izračun gradijenata (Sobel) te primjenu binarnih maski za izdvajanje regije interesa.

Scikit-learn (sklearn): za implementaciju većine modela strojnog učenja (logistička regresija, SVM s RBF jezgrom, RandomForest klasifikator i višeslojni perceptron), standardizaciju značajki (StandardScaler), podjelu podataka na skup za treniranje i skup za testiranje te za izračun metrika performansi.

XGBoost: za implementaciju XGBoost klasifikatora.

NumPy: za efikasne numeričke operacije i rad s višedimenzionalnim poljima (npr. slike, vektori značajki).

Pandas: za manipulaciju podacima, posebice za rad s tablicama značajki i oznakama.

Matplotlib/Seaborn: za vizualizaciju podataka i rezultata, uključujući generiranje grafova prikazanih u radu.

IV. OPIS EKSPERIMENTALNIH REZULTATA

U ovom poglavlju prikazani su rezultati eksperimentalne evaluacije razvijenog sustava za detekciju intracerebralnog krvarenja na CT slikama mozga. Nakon provedene predobrade, segmentacije regije interesa te izdvajanja značajki, dobiveni vektori značajki korišteni su kao ulaz u modele strojnog učenja.

Skup podataka sastoji se od ukupno 200 CT slika, koje su podijeljene na trening i testni skup u omjeru 80:20 uz stratifikaciju za očuvanje omjera klasa (krvarenje / bez krvarenja) u oba skupa. Trening skup sadrži 160 slika, dok testni skup sadrži 40 slika.

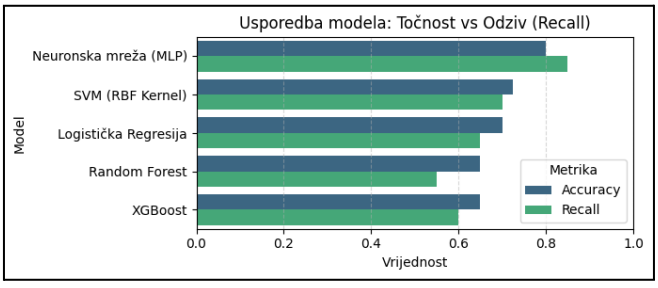
Za svaku sliku izdvojeno je ukupno 13 značajki koje su prije treniranja modela standardizirane kako bi se osigurala usporedivost i stabilno učenje modela, a evaluirano je pet modela strojnog učenja navedenih u prethodnom poglavlju. Rezultati su prikazani u tablici 1

Tablica 1: Usporedba metrika modela

Model	**ACC - Train set**	**Recall - Train Set**	**Accuracy - Test set**	**Recall - Test set**
Logistička regresija	71.88%	0.70	70.00%	0.65
SVM	90.62%	0.83	72.50%	0.70
Random Forest	99.38%	1.00	65.00%	0.55
XGBoost	100%	1.00	65.00%	0.60
Neuronska mreža (MLP)	100%	1.00	80.00%	0.85

Rezultati evaluacije na testnom skupu pokazuju da je neuronska mreža (MLP) ostvarila najbolje performanse, s točnošću od 80% i odzivom od 0.85. Slijedi SVM s RBF jezgrom koji postiže točnost od 72.5% i odziv od 0.70. Logistička regresija ostvarila je umjerene rezultate i na skupu za treniranje i na skupu za testiranje, dok su Random Forest i XGBoost pokazali slabije generalizacijske sposobnosti na testnom skupu, unatoč vrlo visokim rezultatima na skupu za treniranje, što upućuje na prenaučenost modela ili na manjak broja testnih primjera.

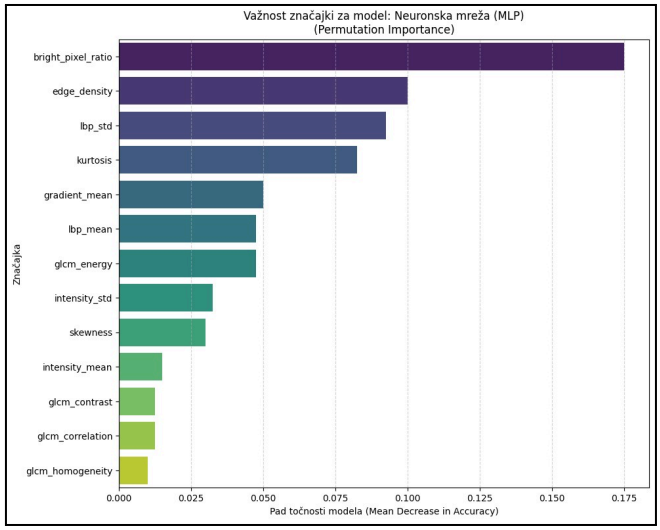
Vizualna usporedba modela pomoću stupčastog grafa dodatno potvrđuje da MLP postiže najbolji kompromis između točnosti i odziva (Slika 4.)



Slika 4. Usporedba metrika modela - stupčasti graf

Dodatnu analizu modela neuronske mreže napravili smo ispitivanjem važnosti pojedine značajke za klasifikaciju korištenjem metode *permutation importance* (Slika 5.) te detaljnijim uvidom u strukturu klasifikacijskih pogrešaka putem matrice zabune (Slika 6.).

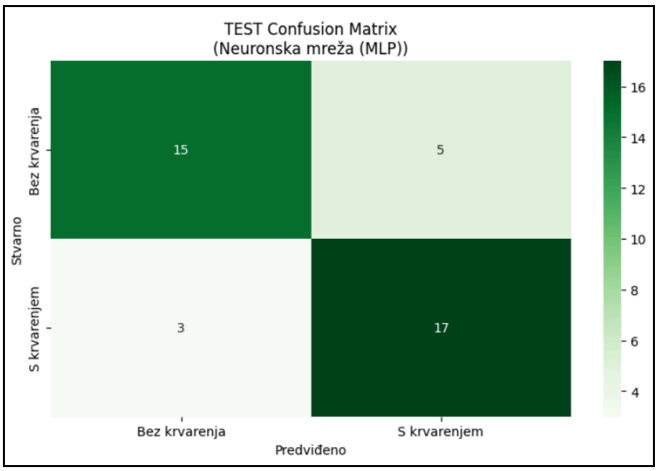
Metoda *permutation importance* za svaku značajku ulaznog skupa ispituje koliko pada točnost modela nakon što se vrijednosti tih značajki nasumično ispremiješaju.



Slika 5. Važnost značajki

Analiza pokazuje kako je daleko najvažnija značajka u klasifikaciji bila značajka intenziteta *bright pixel ratio* - točnost modela padala je u prosjeku za 0.175 kada su njezine vrijednosti bile ispremiješane. Među tri najvažnije značajke su još i značajka ruba *edge density* te teksturalna značajka *lbp_std*, što pokazuje da je upotreba više različitih tipova značajki bila izuzetno korisna.

Gledajući matricu zabune na skupu za testiranje vidimo kako je osam od ukupno 40 primjera bilo pogrešno klasificirano; tri slučaja su tzv. *False Negative* primjeri (model je tri puta propustio identificirati krvarenje), a pet slučaja su *False Positive* primjeri (model pet puta digao "lažnu uzbunu" kod zdravih pacijenata). Iz ovih rezultata vidimo da je model prilično uravnotežen - nema drastične pristranosti (*bias*) prema jednoj klasi.



Slika 6. Matrica zabune na testnom skupu

V. DISKUSIJA

Iz dobivenih rezultata vidimo da se kombinacija ručno izdvojenih značajki, jednostavnih metoda obrade slike i klasičnih modela strojnog učenja može koristiti za uspješno detektiranje intracerebralnog krvarenja na CT slikama. Prednost predloženog pristupa u odnosu na novije i naprednije pristupe je njegova interpretabilnost: jasno je koje značajke (svjetlina, rubovi, tekstura) doprinose odluci modela, što je vrlo važno u medicinskom kontekstu.

Analiza pokazuje da su značajke temeljene na intenzitetu i rubovima posebno informativne, a to je i očekivano s obzirom na to da se intracerebralno krvarenje na CT slikama očituje kao hiperdenzno područje s izraženim i nepravilnim granicama.

Neuronska mreža (MLP) ostvarila je najbolju kombinaciju točnosti i odziva, dok su složeniji ansambl modeli (Random Forest, XGBoost) pokazali znakove prenaučenosti.

Ograničenja ovog rada prvenstveno proizlaze iz veličine i raznolikosti skupa podataka te iz činjenice da se koriste ručno definirane značajke. Iako takav pristup omogućuje bolju kontrolu i razumijevanje modela, moguće je propustiti suptilne obrasce koje duboki modeli s lakoćom mogu uhvatiti.

U literaturi je pokazano da duboki modeli učenja, temeljeni na konvolucijskim neuronskim mrežama, postižu vrlo visoke performanse u detekciji intracerebralnog krvarenja jer automatski uče relevantne značajke iz sirovih CT slika bez potrebe za ručnom ekstrakcijom [2]. Nadalje, u nekim radovima predloženi su hibridni modeli koji kombiniraju konvolucijske neuronske mreže s memorijskim mrežama, poput LSTM-a, kako bi se iskoristila prostorna i sekvencijska informacija iz više CT presjeka, čime se dodatno poboljšava točnost detekcije [2]. Arhitektura takvog modela prikazana je na Slici 7.

Daljnja poboljšanja mogu se postići korištenjem 3D konteksta više CT presjeka, korištenje transfernog učenja (*transfer* learning) te većih i raznovrsnijih skupova podataka što je u prethodnim radovima dovelo do robusnijih modela koji bolje generaliziraju. Takvi pristupi, iako računalno zahtjevniji, predstavljaju prirodan nastavak ovog rada.

VI. ZAKLJUČAK

U ovom radu razvijen je sustav za detekciju intracerebralnog krvarenja na CT slikama mozga korištenjem predobrade slike, ROI segmentacije te izdvajanja značajki intenziteta, rubova i teksture. Svaka slika opisana je s 13 numeričkih značajki koje su korištene kao ulaz u modele strojnog učenja.

Evaluacijom na testnom skupu pokazano je da je neuronska mreža (MLP) ostvarila najbolje rezultate među isprobanim modelima, s točnošću od 80% i odzivom od 0.85. Ostali modeli (SVM, Random Forest, XGBoost) postigli su usporedive vrijednosti točnosti, ali nisu nadmašili neuronsku mrežu po pitanju odziva, a neki su pokazali i znakove prenaučenosti.

Predloženi pristup je jednostavan i lako razumljiv jer se temelji na jasno definiranim koracima obrade slike i značajkama koje imaju smisla u kliničkom kontekstu. Njegova glavna slabost je oslanjanje na ručno izdvojene značajke i izrazito mali skup podataka što je priličan ograničavajući faktor po pitanju mogućnosti generalizacije. Unatoč tome, postignuti rezultati pokazuju da sustav pruža dobru osnovu za daljnji razvoj i uvođenje naprednijih metoda u budućem radu.

VII. LITERATURA

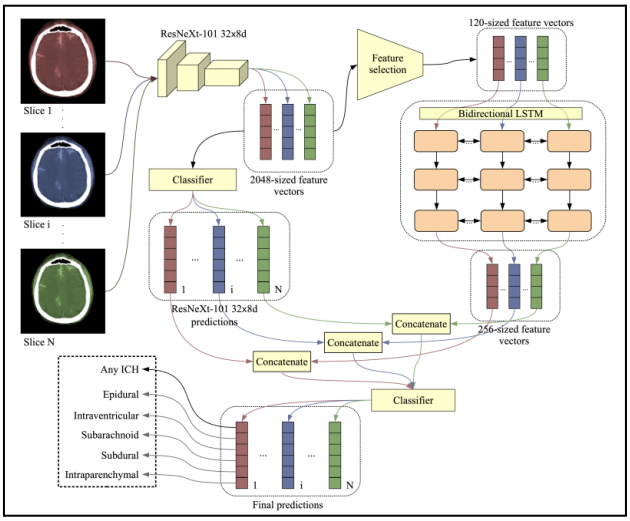
[1] J. H. Powers, A. M. Schwartz i R. J. Hirsch, „Computed Tomography in the Detection of Intracerebral Hemorrhage“, *Radiology*, sv. 126, izd. 1, str. 89–94, siječanj 1978, doi: 10.1148/126.1.89.

[2] M. Burduja, R. Tudor Ionescu i N. Verga, “Accurate and Efficient Intracranial Hemorrhage Detection and Subtype Classification in 3D CT Scans with Convolutional and Long Short-Term Memory Neural Networks,” 2020.

[3] R. M. Haralick, K. Shanmugam i I. Dinstein, „Textural features for image classification“, *IEEE Transactions on Systems, Man, and Cybernetics*, sv. SMC-3, izd. 6, str. 610–621, studeni 1973, doi: 10.1109/TSMC.1973.4309314.

[4] T. Ojala, M. Pietikäinen i T. Mäenpää, „Multiresolution gray-scale and rotation invariant texture classification with local binary patterns“, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, sv. 24, izd. 7, str. 971–987, srpanj 2002, doi: 10.1109/TPAMI.2002.1017623.

[5] N. Otsu, „A threshold selection method from gray-level histograms“, *IEEE Transactions on Systems, Man, and Cybernetics*, sv. 9, izd. 1, str. 62–66, siječanj 1979, doi: 10.1109/TSMC.1979.4310076.



Slika 7. Primjer arhitekture dubokog modela za detekciju intracerebralnog krvarenja koji kombinira konvolucijsku neuronsku mrežu (ResNeXt) i bidirekcijsku LSTM mrežu za obradu više CT presjeka. Preuzeto iz [2].